内存带宽受限下的计算图多核调度问题

Huilin Zhu Xintong Jiang Ruihan Wang

Shanghai Jiao Tong University

问题重述

本题研究多核 NPU 上的计算图划分与调度优化问题。给定由算子、张量及其依赖关系构成的计算图，以及处理器的计算、存储和通信参数，需要合理划分子图、分配计算核，并确定各核内部的执行顺序。

在保证计算正确性和调度合法性的前提下，需要综合考虑负载均衡、计算并行度、数据复用、跨核通信及片上存储容量。这些因素相互制约：提高并行度可能增加通信和数据搬运开销，集中执行有利于数据复用，却可能降低多核利用率。因此，需要协调计算、存储与通信之间的关系，尽量缩短整个计算图的执行时间，提升多核执行的加速效果。

模型概述

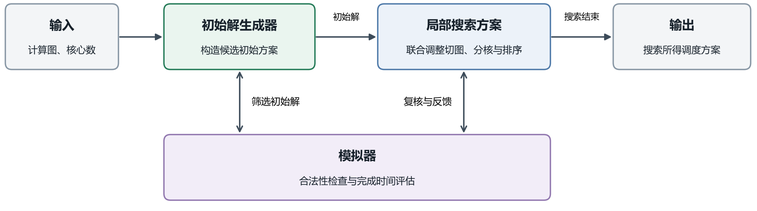


Figure 1. 联合优化模型的运行流程

模型以计算图和核心数为输入，先由初始解生成器构造候选方案，再通过局部搜索联合调整切图、分核与核内顺序。模拟器贯穿两个阶段，检查合法性并评估完成时间，为筛选和迭代提供反馈，最终输出搜索所得的最优可行方案。

优化目标（总）

变量	含义	变量	含义	变量	含义
g	子图划分	a	核心分配	σ	核内顺序
$\mathcal{F}$	可行方案	c,p	核心、管道	T	完成时间
$W_{c,p}$	计算时间	$C^{\text{base}}_{c,p}$	基础搬运	$C^{\text{spill}}_{c,p}$	换出换入
$I_{c,p}$	空闲时间	χ	跨核读取	r	复用间隔
ρ	容量占比	z	换出入次数	$\mathcal{S}$	调度方案

以方案 $\mathcal{S}=(g,a,\sigma)$ 联合描述切图、分核与核内执行顺序，在可行方案集合 $\mathcal{F}$ 中最小化整图完成时间：$\min_{\mathcal{S}\in\mathcal{F}} T(\mathcal{S})$

$$T(\mathcal{S})=\max_{c,p}\Big[W_{c,p}(g,a)\ +C^{\text{base}}_{c,p}(\mathcal{S};\chi,r)+C^{\text{spill}}_{c,p}(\mathcal{S};\rho,z)\ +I_{c,p}(\mathcal{S})\Big].$$

初始解生成器

预处理保留计算依赖，合并共享写者与短链，建立无环分组；随后枚举活动核心数，从三个方面构造初始候选。

- 遍历方案：稳定拓扑序、逆向 DFS 序、关键路径优先序。
- 分核策略：通信感知贪心、累计工作量切分，并保留单核候选。
- 核内顺序：复用优先、释放优先，以及共享张量使用者前移。

候选经模拟器复核，按完成时间和搬运量选优，作为后续搜索起点。

局部搜索方案

围绕负载、复用、数据生命周期和就绪顺序构造候选，四类策略可组合应用。

- 计算均衡：调整分核，减少负载差异。
- 数据局部性：集中共享输入的操作，增加复用。
- 存储驻留与换出：缩短张量存活，减少额外搬运。
- 依赖与资源等待：调整就绪顺序，减少管道空闲。

候选统一经过去重、资源筛选和模拟复核，优先缩短时间，同等时间减少搬运；从不同分区与排序起点重复搜索。

计算均衡

通过调整活动核心数和任务归属，减少各核完成时间的差异。

- 分核方式：连续切分、块轮转与最轻核分配。
- 尾块分摊：对齐主体块，分配剩余条带。
- 链迁移：尝试整链或半链迁核，联动共享写者。

数据局部性

使共享输入的计算单元相邻执行，减少重复加载与复用中断。

- 分块遍历：枚举矩形块形状及行、列、蛇形顺序。
- 空间分区：按输入共现划分条带，调整边界与广播归属。
- 子图粒度：固定操作序列，比较不同连续分组大小。

存储驻留与换出

结合缓存容量调整分块与排序，缩短中间数据驻留，减少换出换入。

- 生命周期：同核延后生产者、提前消费者。
- 容量分块：调整块形状、跨块组合数与链深度步长。
- 就绪重排：兼顾减少新增驻留与增加内存释放。

依赖与资源等待

固定分核后，结合依赖到达与管道可用时间重排操作，改善流水重叠。

- 开始时间：综合前驱完成、跨核等待与管道占用。
- 窗口排序：改变就绪窗口大小与管道偏好。
- 分层重排：对混合管道图前移依赖层前缀。

模拟器

使用 C++ 实现测评核心执行逻辑，加快候选评估，为初始解和局部搜索提供反馈。

- 模拟内容：管道执行、跨核搬运、换出换入与共享 DDR 竞争。
- 评估输出：方案合法性、完成时间与搬运量。

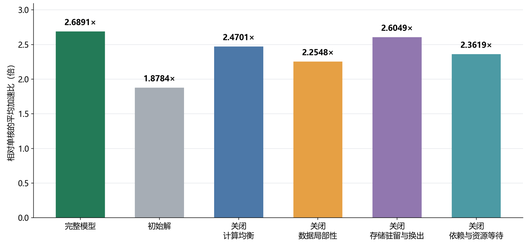


Figure 2. 四组搜索策略消融的平均加速比对比

加速比结果

Table 1. 完整模型的加速比与理论上界对比

算例	2 核 加速比	2 核 理论上界	3 核 加速比	3 核 理论上界	4 核 加速比	4 核 理论上界	5 核 加速比	5 核 理论上界
算例 00	1.9965×	**1.99951**×	2.8639×	**2.99788**×	3.5174×	**3.99532**×	3.5174×	**4.98608**×
算例 01	1.0028×	**1.00600**×	1.0028×	**1.00600**×	1.0028×	**1.00600**×	1.0028×	**1.00600**×
算例 02	1.0000×	**1.00000**×	1.0000×	**1.00000**×	1.0000×	**1.00000**×	1.0000×	**1.00000**×
算例 03	1.9986×	**2.00017**×	2.8338×	**2.99948**×	3.5432×	**3.99826**×	3.5432×	**4.28194**×
算例 04	1.9982×	**1.99976**×	2.9303×	**2.99894**×	3.7181×	**3.99766**×	3.7181×	**4.99375**×
算例 05	1.9992×	**1.99991**×	2.9575×	**2.99961**×	3.7624×	**3.99913**×	3.7624×	**4.56417**×
算例 06	1.9969×	**1.99928**×	2.9159×	**2.99752**×	3.5883×	**3.99485**×	3.5883×	**4.98549**×
算例 07	2.0547×	**2.10861**×	2.9310×	**3.16222**×	3.7164×	**4.21536**×	4.3175×	**5.26803**×
算例 08	2.3270×	**2.55026**×	3.2039×	**3.82521**×	3.8243×	**5.10003**×	4.1271×	**6.37222**×
算例 09	2.1755×	**2.26568**×	2.9958×	**3.39835**×	3.4326×	**4.53089**×	3.6968×	**5.66332**×
平均	1.8549×	**1.89292**×	2.5635×	**2.73852**×	3.1106×	**3.58375**×	3.2274×	**4.31210**×

40 **组配置相对单核的平均加速比（算术平均）**：2.6891 **倍**。

加速比上界分析

加速比上界

设 T_{base} 为固定单核基线时间，$T_k^\star$ 为所有合法 k 核方案中的最短执行时间。若三个模块分别给出有效时间下界 L_{DAG}、L_{mem}、L_{spec}，则

$$S_k^{\max}=\frac{T_{\text{base}}}{T_k^\star}\le\min\left\{\frac{T_{\text{base}}}{L_{\text{DAG}}},\frac{T_{\text{base}}}{L_{\text{mem}}},\frac{T_{\text{base}}}{L_{\text{spec}}}\right\}.$$

- **DAG 与资源下界**：根据各 Pipe 的工作量、必需数据搬运和操作的前后依赖，推导完成全部任务至少需要的时间。
- **有限内存下界**：计算在缓存容量限制下，至少需要搬运多少数据，再用“最低搬运量 ÷ DDR 带宽”得到时间下界。
- **结构专项下界**：利用规则图的累加链结构，分段统计输入和中间结果，用动态规划求最有利的数据复用方式，推导即使如此仍无法省去的执行时间。

三个时间下界取最大值，等价于三个加速比上界取最小值。所得上界不保证能够达到。

消融实验

在相同初始解和硬件参数下，分别关闭四组搜索策略。完整模型相对单核的平均加速比为 2.6891 **倍**，优于各消融版本。表明这两组策略在当前测试集中的贡献更明显：前者促进数据复用、减少重复搬运，后者改善执行顺序、减少管道空闲。计算均衡通过分摊负载缓解瓶颈核心，存储驻留优化通过缩短张量生命周期减少换出换入，进一步改善整体表现。

结论

本研究构建了联合优化子图划分、核心分配与核内顺序的调度框架，通过模拟器评估和局部搜索，协调负载均衡、数据复用与存储开销。完整模型在 40 组配置中取得平均 2.6891 **倍**加速比，部分低核数配置已接近理论上界；消融实验表明，各组搜索策略对整体性能具有互补作用。

启示与猜测：多核调度需要同时关注计算并行与数据搬运。随着核数增加，性能瓶颈可能逐渐转向共享带宽和依赖等待，进一步优化可重点探索跨核数据复用与计算、通信重叠。